Pontificia Universidad JAVERIANA Colombia

RAG con citas

Semana 4 · Embeddings, vector stores y respuestas con fuentes
Tópicos Avanzados en Analítica II – IA Generativa
Maestría en Analítica para la Inteligencia de Negocios

Sergio Alberto Mora Pardo - H1 2027
GitHub · LinkedIn · Repositorio del curso

Tópicos Avanzados en Analítica II

Estructura del curso

Fundamentos con LangChain
Semanas 1–3 ✓

RAG y evaluación
Semanas 4–6

Model Context Protocol
Semana 7

LangGraph y patrones agénticos
Semanas 8–11

LLMOps y despliegue
Semana 12

Semana 4 · Embeddings, vector stores y RAG

- Cuando la respuesta vive en un PDF
- Cargar, fragmentar y convertir en vectores
- Similitud coseno y distancia
- FAISS y Chroma: persistir el índice
- Recuperar, generar y citar la fuente
- Preguntas sin respuesta en los documentos

Las ideas que traemos de la semana 3

Repaso

Antes de avanzar

1. El modelo propone una herramienta; nuestro código la ejecuta.
2. La cartera de créditos es un dato estructurado: se consulta con parámetros.
3. Las cifras de la respuesta deben coincidir con las de la herramienta.

Cuando la respuesta vive en un documento

El problema de la semana

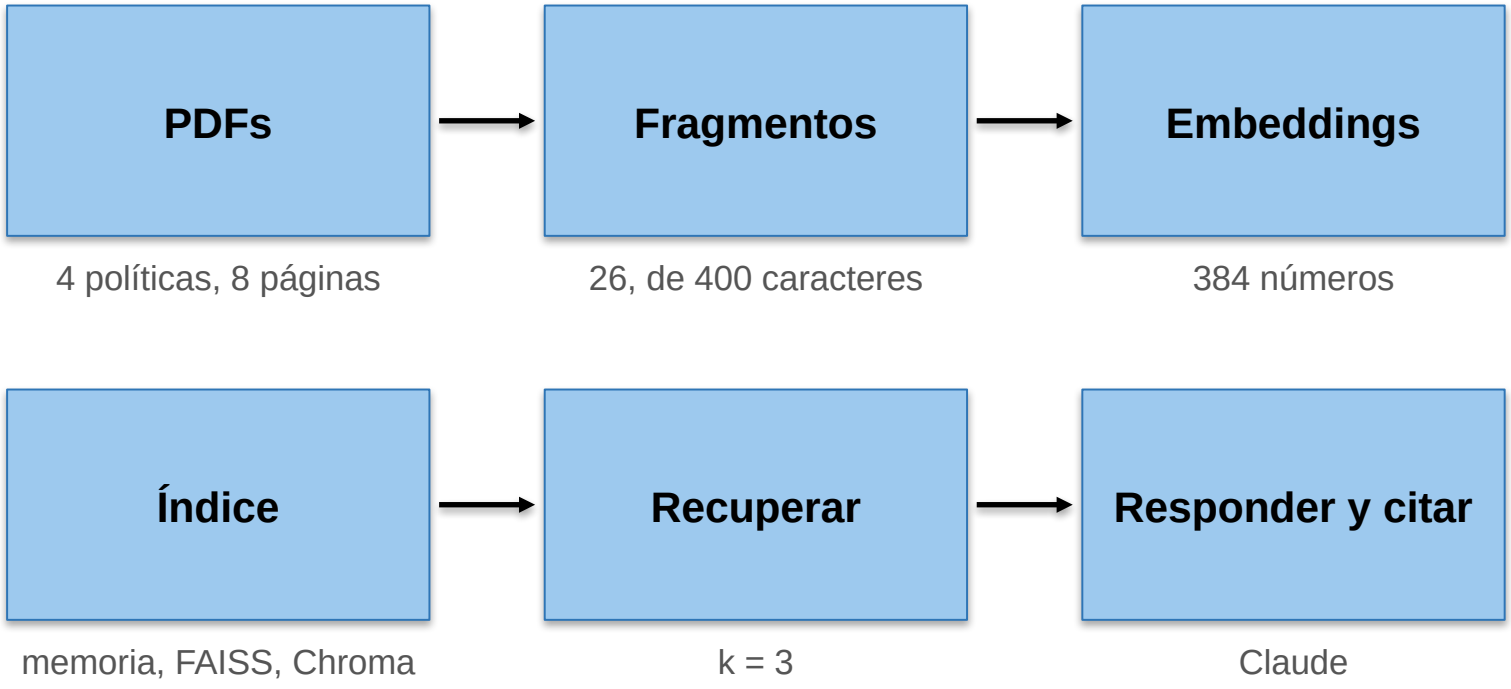
Texto, no tabla

«Firmé un Crédito Libre Inversión un viernes a las 5 de la tarde. ¿Cuándo me llega el dinero?»

La respuesta está en la **política de desembolsos**, un PDF. Primero hay que **encontrar** el fragmento que habla del tema.

El recorrido de RAG

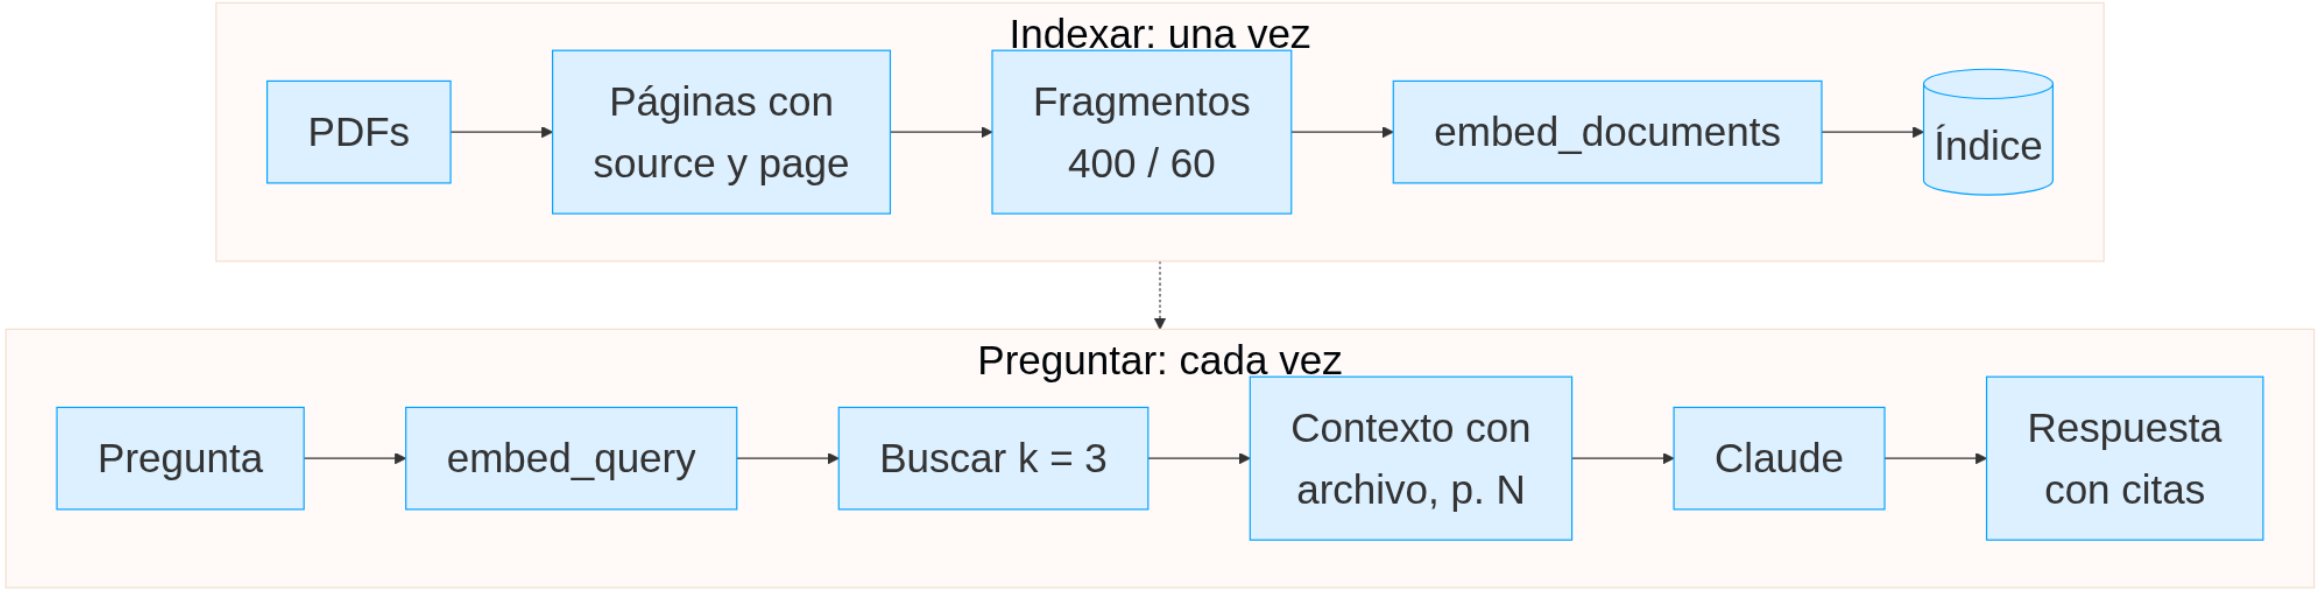
Retrieval-Augmented Generation



Todo excepto la última caja corre en el equipo, sin costo por uso.

Dos momentos de un RAG

Indexar una vez, preguntar cada vez



Indexar y preguntar. Indexar corre en el equipo y se repite solo si cambian los documentos; cada pregunta recorre la segunda mitad.

Pontificia Universidad JAVERIANA Colombia

Embeddings

Texto convertido en vectores

Cargar y fragmentar

L06 · secciones 1 y 2

Unidades de búsqueda

1. `PdfReader` lee cada página; la metadata guarda `source` y `page` para citar.
2. `RecursiveCharacterTextSplitter(chunk_size=400, chunk_overlap=60)`: 8 páginas → 26 fragmentos.
3. Fragmentos pequeños: más precisos, pero pierden contexto (120 caracteres → 102 fragmentos).
4. El solapamiento evita cortar una regla entre dos fragmentos.

Elegir el tamaño del fragmento

L06 · sección 2

Elección	Ventaja	Costo
Fragmentos pequeños (120, 102 fragmentos)	Más precisos para una pregunta puntual	Pierden el contexto de la regla
Fragmentos medianos (400, 26 fragmentos)	Una regla completa por fragmento	Pueden mezclar dos temas
Fragmentos grandes o páginas enteras	Todo el contexto	Más tokens por pregunta y búsqueda menos fina
Solapamiento (60)	Una regla partida aparece entera en algún fragmento	Texto repetido en el índice

Medir la cercanía

L06 · secciones 3 y 4

Frase	Similitud coseno con la pregunta
Pregunta: «¿Cuánto tarda en llegar la plata del crédito?»	—
«Crédito Express: el dinero llega en menos de 15 minutos…»	0,625
«Desde los 20 días de atraso se suma un cargo fijo…»	0,288

Dos métodos para dos papeles

embed_documents y embed_query

Método	Qué representa
`embed_documents`	Los fragmentos del índice, una vez
`embed_query`	La pregunta, en cada búsqueda
Mismo modelo	Ambos vectores deben venir del mismo modelo para compararse

Tres formas de medir cercanía

Similitud y distancia

Medida	Qué compara	Lectura
Similitud coseno	El ángulo entre los vectores	Mayor es más cerca; ignora la longitud
Distancia L2 (euclidiana)	La distancia entre las puntas	Menor es más cerca; depende de la longitud
Producto punto	Ángulo y longitud a la vez	Mayor es más cerca
Con vectores normalizados	Longitud 1	Las tres ordenan igual

Pontificia Universidad JAVERIANA Colombia

Vector stores

Guardar el índice y buscar en él

Tres índices, los mismos fragmentos

L06 y L07

Índice	Qué es	Cuándo usarlo
`InMemoryVectorStore`	Una lista en memoria	Clase y prototipos
FAISS	Biblioteca de búsqueda; guarda archivos	Búsquedas rápidas sin servidor
Chroma	Base de datos vectorial ligera	Persistencia y filtros por metadata

Chroma con filtro por metadata

L07 · secciones 4 y 5

Buscar solo en cobranza

FAISS y Chroma devuelven distancia: menor es mejor.

Cómo funciona

1. Chroma guarda los fragmentos con sus embeddings en disco, con distancia coseno.

2. Cada fragmento conserva su metadata: archivo y página.

3. La búsqueda filtra por archivo y devuelve los tres más cercanos con su distancia.

La métrica importa

L07 · sección 6

Coseno y distancia

1. Los vectores de este modelo no tienen longitud 1.
2. Sin normalizar, la distancia L2 premia fragmentos largos y genéricos.
3. FAISS: `normalize_L2=True`. Chroma: `hnsw:space = cosine` al crear la colección.
4. Con la misma métrica, los tres índices devuelven los mismos fragmentos.

Pontificia Universidad JAVERIANA Colombia

RAG

Recuperar primero, generar después

Responder con fuentes

L08 · secciones 2 a 4

Una cadena con @chain

El prompt pide citar [archivo, p. N] después de cada dato.

Cómo funciona

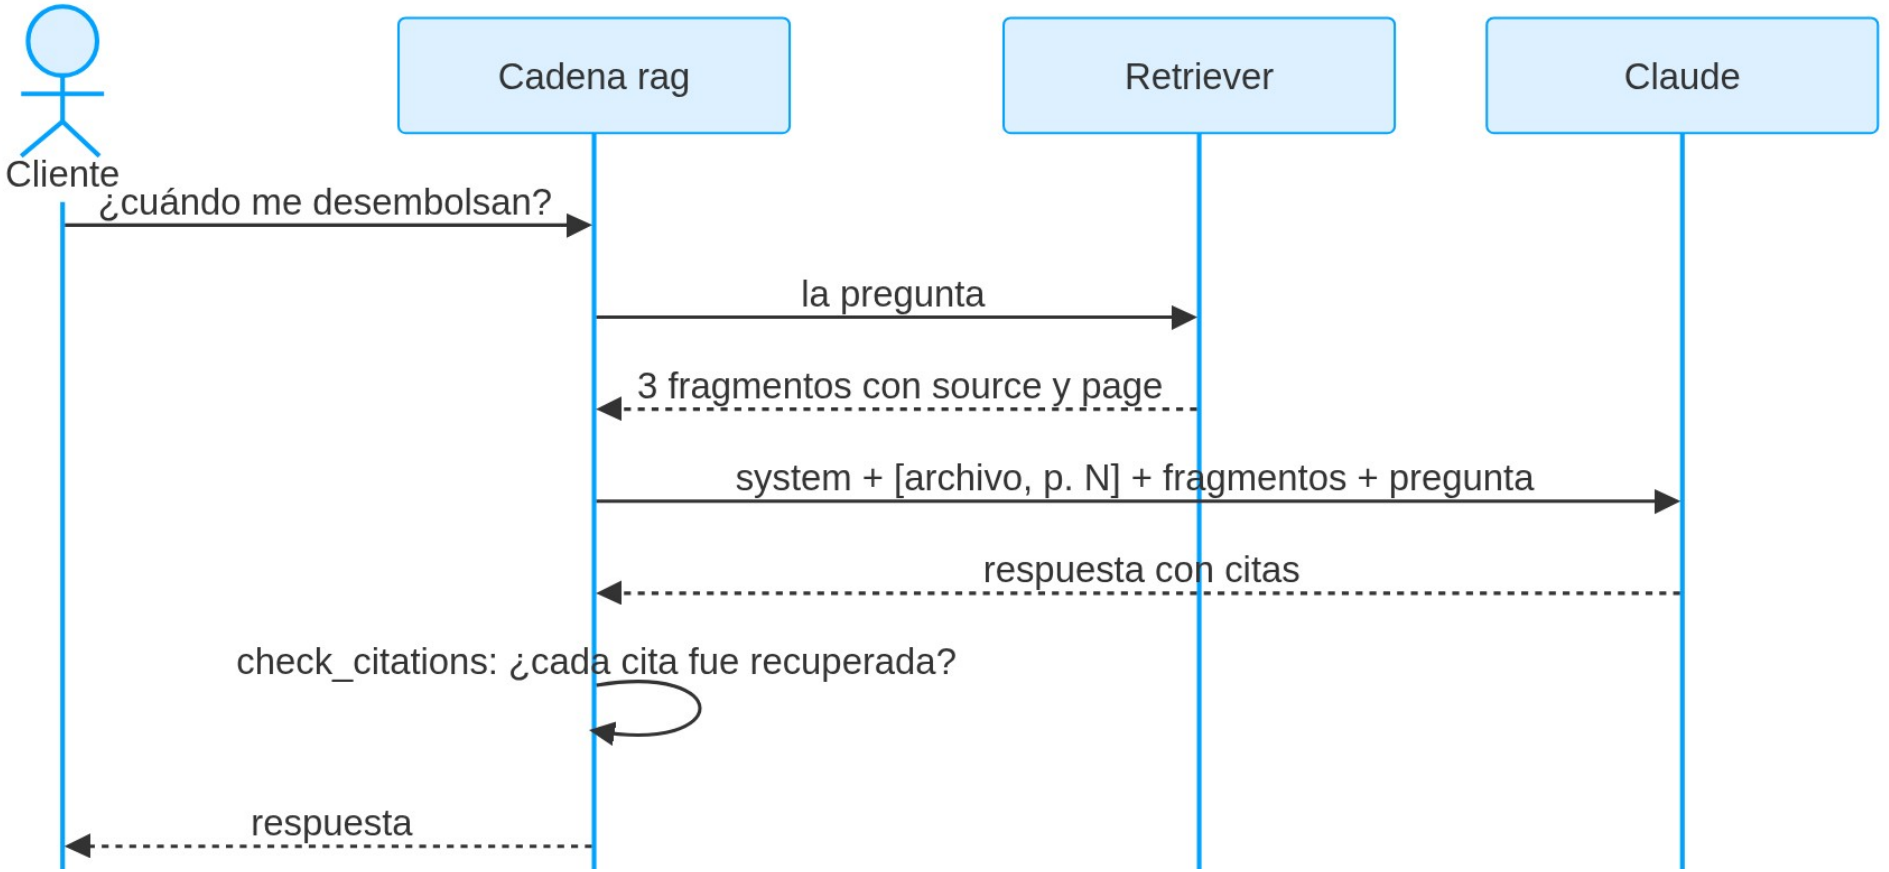
1. El retriever trae los tres fragmentos más parecidos a la pregunta.

2. Cada fragmento entra al prompt con su etiqueta [archivo, p. N].

3. El modelo responde con ese contexto y cita la fuente de cada dato.

Una pregunta de principio a fin

L08 · diagrama de secuencia



Recuperar, generar, comprobar. El modelo solo ve los 3 fragmentos; la comprobación de citas corre en código, sin modelo.

Cuando los documentos no responden

L08 · secciones 4 a 6

Decir «no está»

1. «¿Qué beneficios tiene la tarjeta de crédito?»: ninguna política lo cubre.
2. El prompt pide decir qué no está en los documentos consultados.
3. Cambiar el retriever (memoria → Chroma) no cambia el resto de la cadena.
4. Sin modelo, comprobamos que cada cita corresponde a un fragmento recuperado.

Errores típicos de un RAG

Síntoma y control

Error	Síntoma	Control
No se recupera la página correcta	La respuesta dice «no está» aunque sí está	Medir la recuperación con preguntas de referencia
Fragmentos que no ayudan	Una respuesta vaga o de otro producto	La regla «si no está, dilo» y un `k` medido
Cita inventada	Cita una página que no se recuperó	`check_citations` en código
Dato sin sustento	Una cifra que no está en los fragmentos	Juez de groundedness (semana 6)
Documento desactualizado	Una regla que ya cambió	Versión y fecha en los documentos, reindexar al cambiar

Pontificia Universidad JAVERIANA Colombia

Laboratorio

L06-Embeddings · L07-VectorStores · L08-RAG

¿Qué haremos?

Laboratorio

Nuestro recorrido

1. L06: cargar las políticas, fragmentar y medir similitudes (0 llamadas).
2. L07: el mismo índice en FAISS y Chroma, con filtros (0 llamadas).
3. L08: recuperar, responder citando y probar una pregunta sin respuesta (3 llamadas).
4. Práctica: una pregunta propia sobre las políticas y su comprobación de citas.

Las ideas que nos llevamos

Cierre

Criterios de construcción

1. La recuperación decide qué puede saber el modelo.
2. La metadata hace posible citar archivo y página.
3. La métrica y la normalización cambian el ranking.
4. «No está en los documentos» es una respuesta correcta.

Para seguir leyendo

Lecturas de la semana

Fuente	Qué revisar
Learning LangChain, cap. 2 y 3	Indexar y conversar con los datos
AI Engineering, cap. 6	RAG: recuperación y sus métricas
Documentación de FAISS y Chroma	Índices, métricas y persistencia

Pontificia Universidad JAVERIANA Colombia

Próxima semana

RAG conversacional y **memoria**: preguntas de seguimiento.
Notebooks:
`L09-ConversationalRAG.ipynb`
`L10-Memory.ipynb`

Sergio Alberto Mora Pardo - H1 2027
GitHub · LinkedIn · Repositorio del curso