Pontificia Universidad JAVERIANA Colombia

MCP: conectar agentes y datos

Semana 7 · Construir y consumir servidores MCP
Tópicos Avanzados en Analítica II – IA Generativa
Maestría en Analítica para la Inteligencia de Negocios

Sergio Alberto Mora Pardo - H1 2027
GitHub · LinkedIn · Repositorio del curso

Tópicos Avanzados en Analítica II

Estructura del curso

Fundamentos con LangChain
Semanas 1–3 ✓

RAG y evaluación
Semanas 4–6 ✓

Model Context Protocol
Semana 7

LangGraph y patrones agénticos
Semanas 8–11

LLMOps y despliegue
Semana 12

Semana 7 · Model Context Protocol

- Una integración para varias aplicaciones
- Host, cliente, servidor y modelo
- Tools, resources y prompts
- Python asíncrono: `async` y `await`
- Un servidor de créditos sobre SQLite
- Un agente con dos servidores
- stdio, HTTP, Claude Code y seguridad

Las ideas que traemos de la semana 6

Repaso

Antes de avanzar

1. Una evaluación compara configuraciones con la misma entrada.
2. Las comprobaciones de código van primero; el juez se calibra.
3. Una cita no basta: hay que comprobar que viene de lo recuperado.

Una consulta, varias aplicaciones

El problema de la semana

¿Cómo compartimos la herramienta?

La consulta de la cartera vive en un notebook (`@tool`).

El asistente de soporte, Claude Code y otra aplicación del equipo necesitan **la misma consulta**.

¿Copiamos el código en cada una?

Qué es MCP

Model Context Protocol

Un protocolo abierto

Un contrato común para **descubrir** y **usar** herramientas, datos y plantillas de otros programas.

Un **servidor MCP** es el programa que ofrece esas capacidades. «Conectar un MCP» suele significar conectar un servidor.

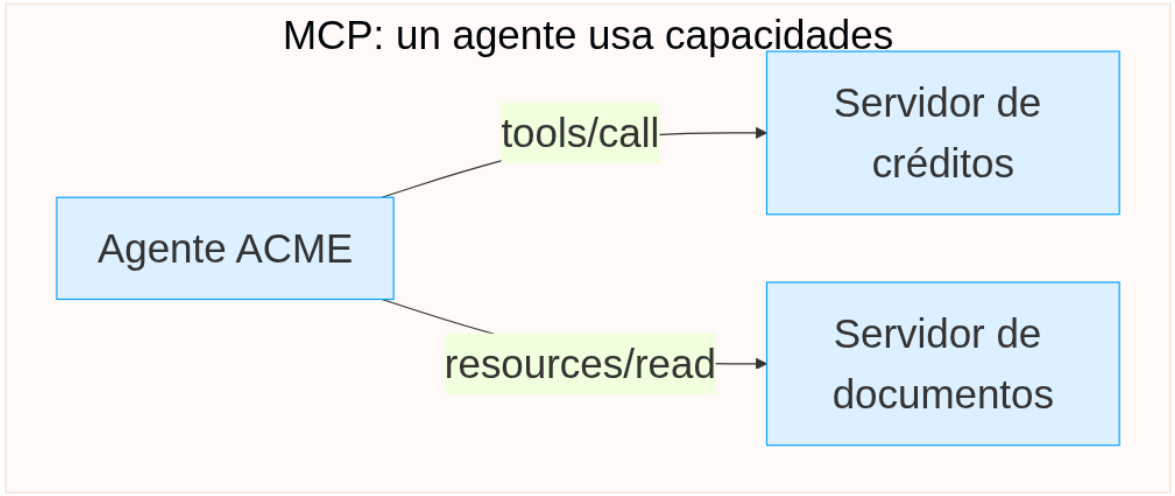
MCP frente a otras integraciones

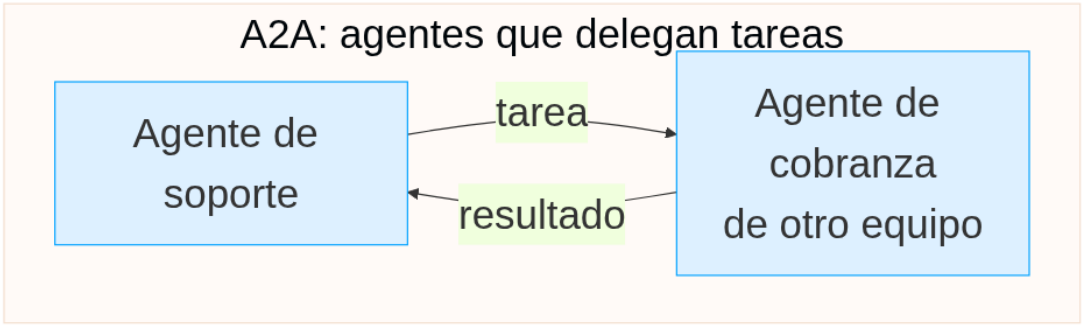
Qué resuelve cada una

Integración	Quién habla con quién	Para qué sirve
Function calling	El modelo propone; la app ejecuta sus funciones	Herramientas que viven dentro de una app
API REST (OpenAPI)	Un programa llama a otro sistema	Integraciones entre sistemas, sin contrato para modelos
MCP	Una app (cliente) descubre y usa un servidor	Compartir herramientas, datos y plantillas entre apps
A2A (Agent2Agent)	Un agente delega una tarea a otro agente	Coordinar agentes de equipos o proveedores distintos

MCP y A2A

Capacidades frente a tareas

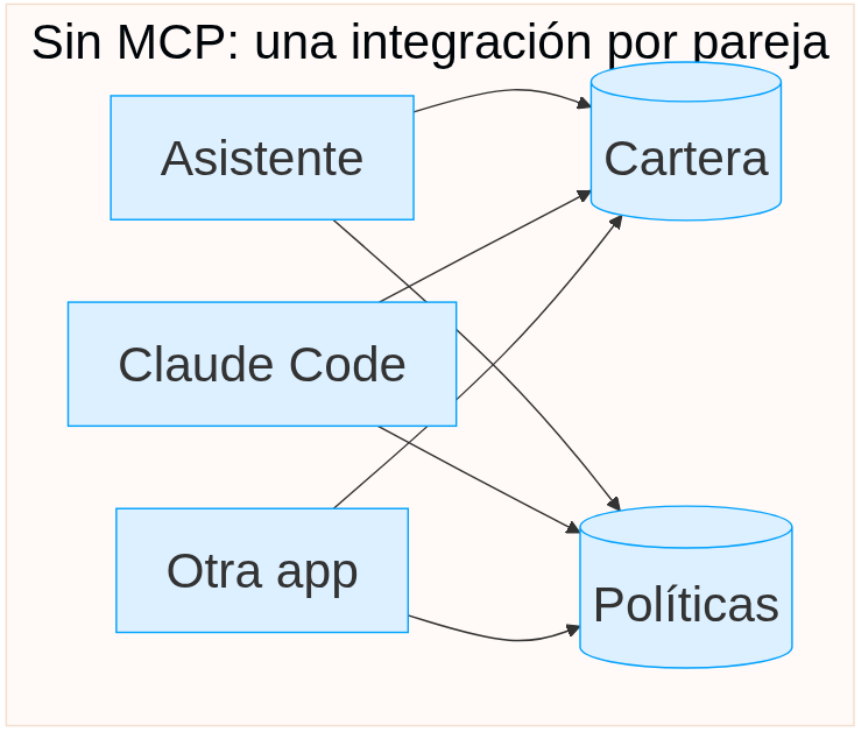


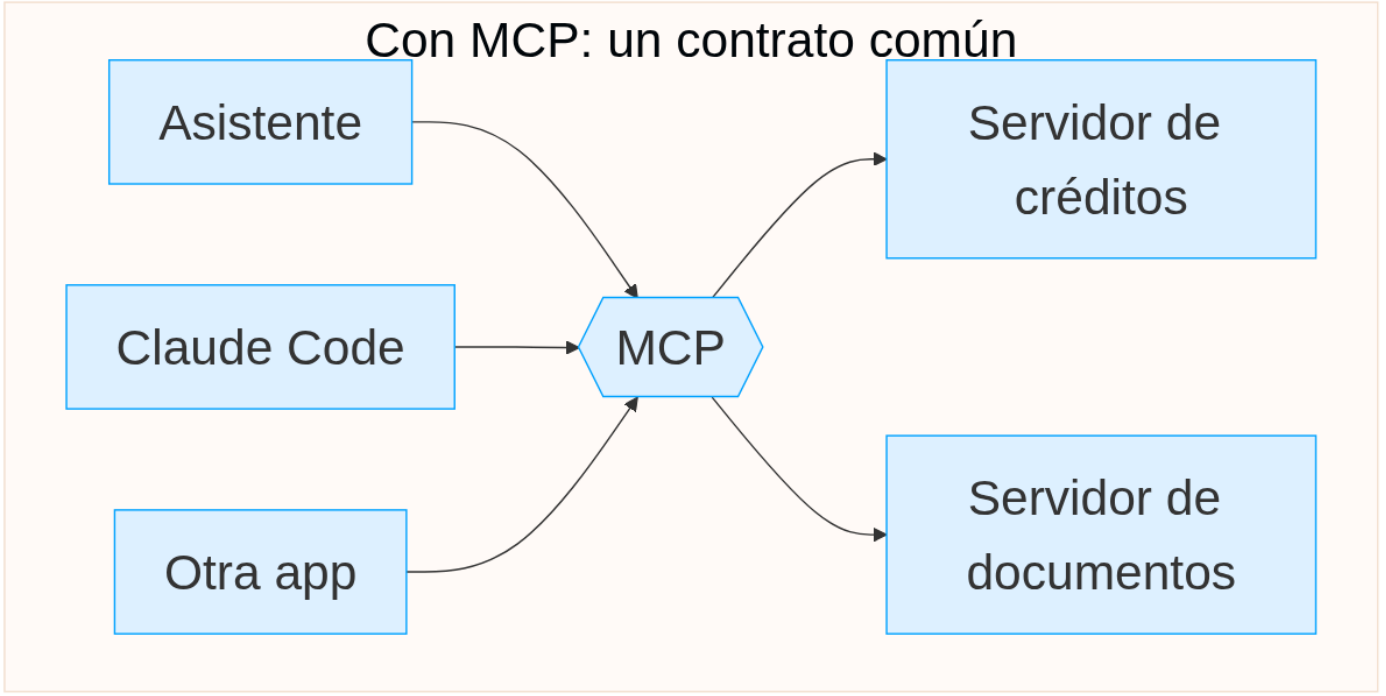


Dos protocolos. Con MCP el agente usa capacidades de un servidor; con A2A le pide una tarea completa a otro agente, sin ver cómo la resuelve.

Antes y después de MCP

Integraciones





De N × M a N + M. Sin MCP, cada app reimplementa cada integración. Con MCP, cada sistema se expone una vez como servidor.

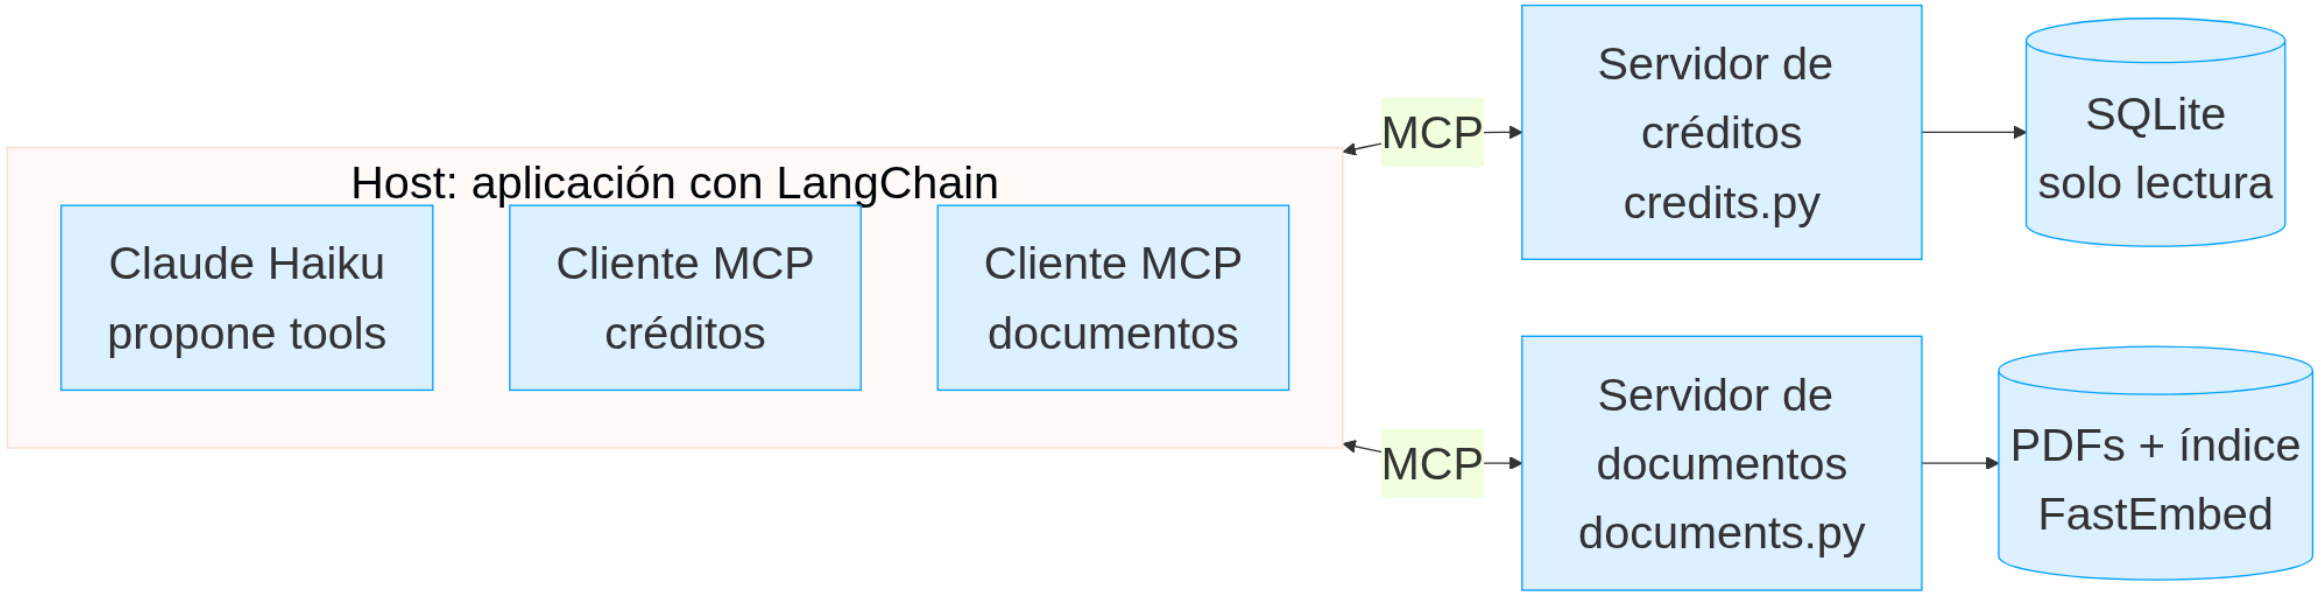
Quién hace cada parte

Responsabilidades de la integración

Componente	Responsabilidad	En el laboratorio
Host	Coordina modelo, clientes y permisos	La aplicación del notebook
Cliente MCP	Habla el protocolo con un servidor	`Client` del SDK o `MCPAdapter`
Servidor MCP	Expone y ejecuta capacidades	`credits.py` y `documents.py`
Modelo	Propone tools y redacta la respuesta	Claude Haiku

Una aplicación, dos servidores

La arquitectura del laboratorio



Un cliente por servidor. El host contiene un cliente MCP por cada servidor. El modelo nunca habla directo con los servidores.

Las tres primitivas del servidor

Quién dirige su uso

Primitiva	Quién la elige	En ACME
Tool	El modelo propone la operación	`check_credit`, `search_documents`
Resource	La aplicación elige qué leer, por URI	`schema://credits`, `docs://{name}`
Prompt	La persona elige una plantilla	«Solicitud de reestructuración»

El recorrido de una consulta

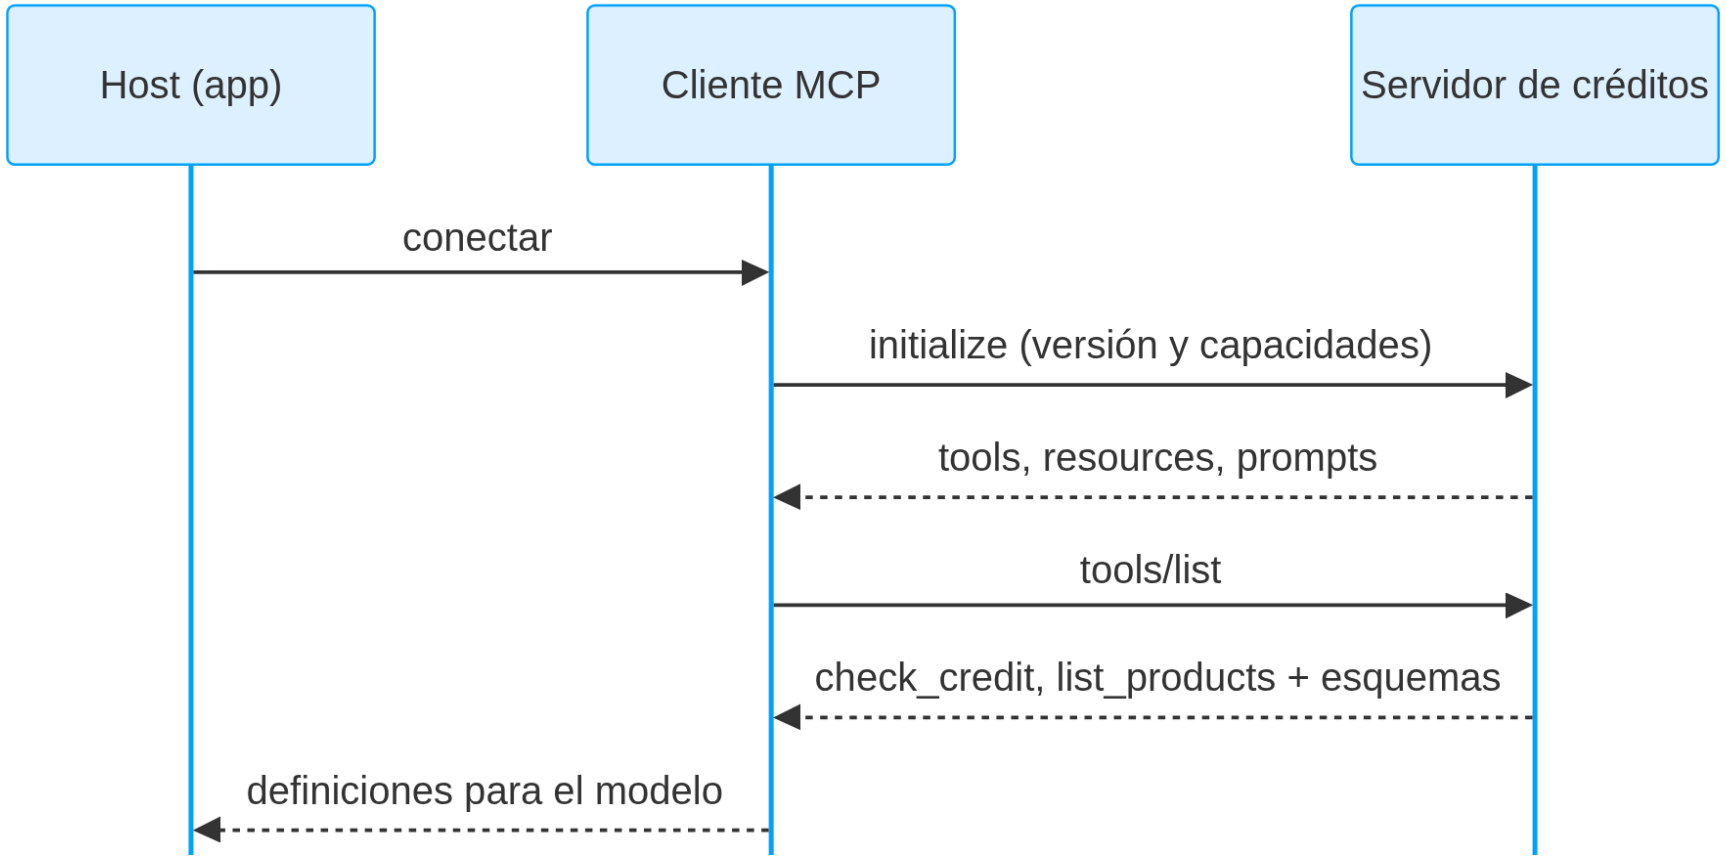
Después del descubrimiento (tools/list)



El modelo propone; la aplicación ejecuta; el servidor implementa la operación.

Una sesión MCP: descubrir

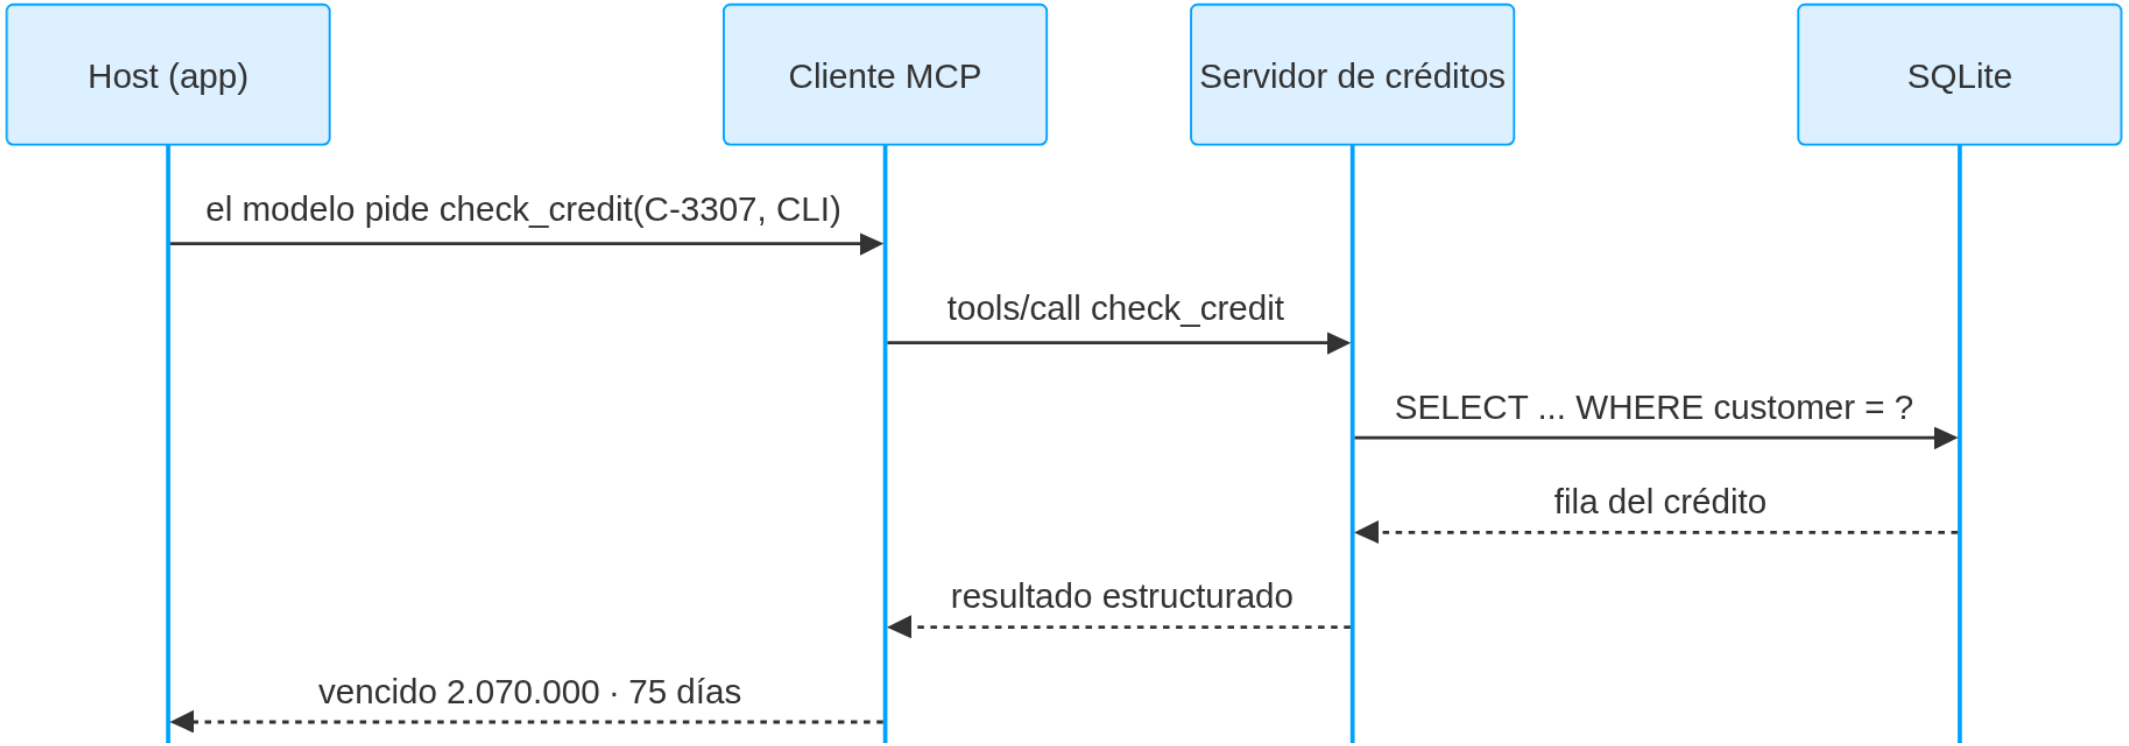
Diagrama de secuencia · 1 de 2



Descubrir. `initialize` acuerda la versión del protocolo y las capacidades; `tools/list` publica el contrato que verá el modelo.

Una sesión MCP: llamar

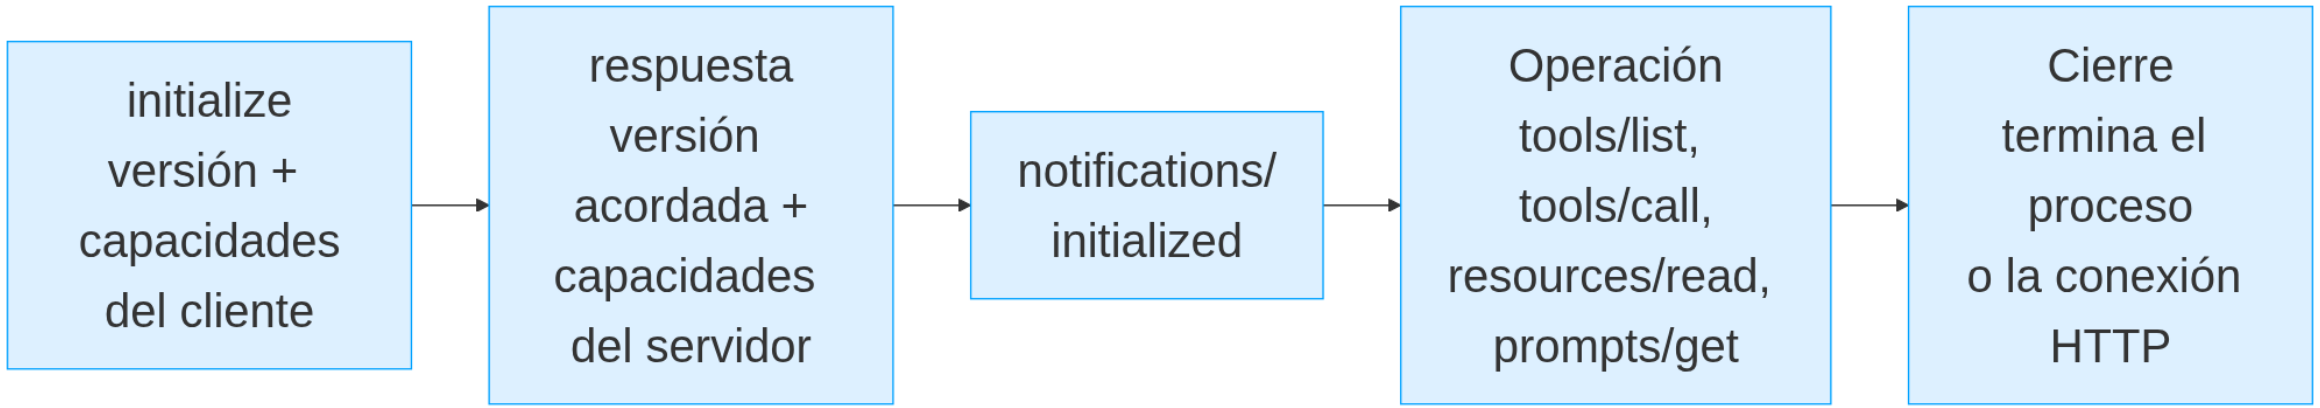
Diagrama de secuencia · 2 de 2



Llamar. `tools/call` usa el contrato. El servidor valida y consulta SQLite con parámetros (?): el modelo nunca ve el SQL.

Las fases de una sesión

Ciclo de vida



De initialize al cierre. Primero se acuerdan la versión y las capacidades; solo después se listan y usan herramientas, recursos y prompts.

Capacidades que se negocian

Qué declara cada lado en initialize

Lado	Capacidad	Qué permite
Servidor	`tools`	Que el cliente liste y llame herramientas
Servidor	`resources`	Que el cliente lea datos por URI
Servidor	`prompts`	Que la persona elija plantillas
Servidor	`logging`	Enviar registros al cliente
Cliente	`elicitation`	Que el servidor pregunte algo a la persona
Cliente	`sampling`, `roots`	Que el servidor pida una respuesta al modelo, o sepa qué carpetas puede usar

Pontificia Universidad JAVERIANA Colombia

Construir el servidor

L12-MCPServer · sin modelo

Una tool en un servidor MCP

src/agents/servers/credits.py

El contrato

Tipos y descripciones forman el esquema que ve el modelo.

Cómo funciona

1. Un servidor MCP publica la herramienta que consulta créditos.

2. La anotación de solo lectura y la docstring describen su efecto.

3. Los tipos de entrada y salida forman el esquema que reciben los clientes.

Python asíncrono: async y await

Antes de hablar MCP desde Python

Esperar sin bloquear

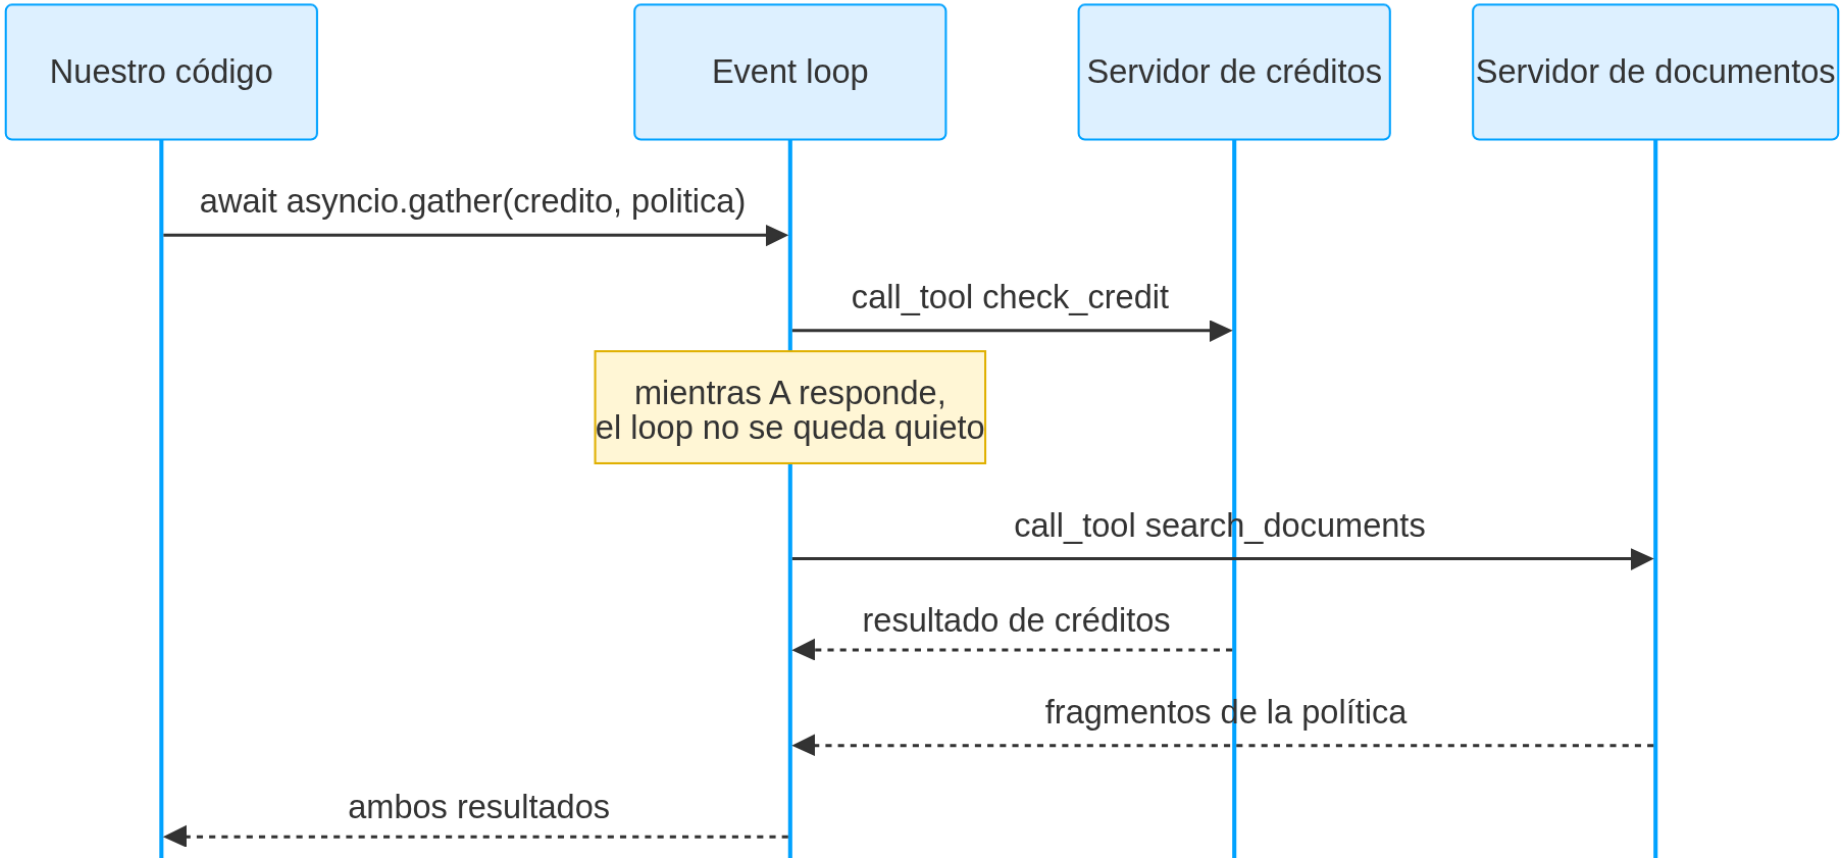
Una llamada MCP espera E/S: un proceso o una red. await cede el turno mientras llega la respuesta.

Cómo funciona

1. `async def` define una corrutina: no corre hasta que alguien la espera.
2. `async with` abre la sesión MCP y la cierra al salir.
3. `await` cede el turno mientras llega la respuesta del servidor.
4. En un script se arranca con `asyncio.run`; en Jupyter basta `await`.

El event loop

Varias esperas al mismo tiempo



asyncio.gather. Ilustración: dos servidores consultados a la vez. El tiempo total es el del más lento, no la suma.

Hablar MCP sin modelo

L12 · secciones 3 a 5

Descubrir y llamar

Probar el servidor no gasta tokens.

Cómo funciona

1. Un cliente MCP se conecta al servidor sin ningún modelo de por medio.

2. Lista las herramientas, llama una con argumentos y lee un recurso.

3. Así se prueba el servidor completo sin gastar tokens.

Validar y fallar bien

L12 · sección 4

Controles en el código

1. La conexión SQLite se abre en modo solo lectura (`mode=ro`).
2. La consulta usa parámetros; nunca concatena la entrada del usuario.
3. Un código de cliente inválido produce un `ToolError` claro.
4. `read_only_hint` informa al cliente, pero no impide una escritura: eso lo hace el código.

Preguntar a la persona: elicitation

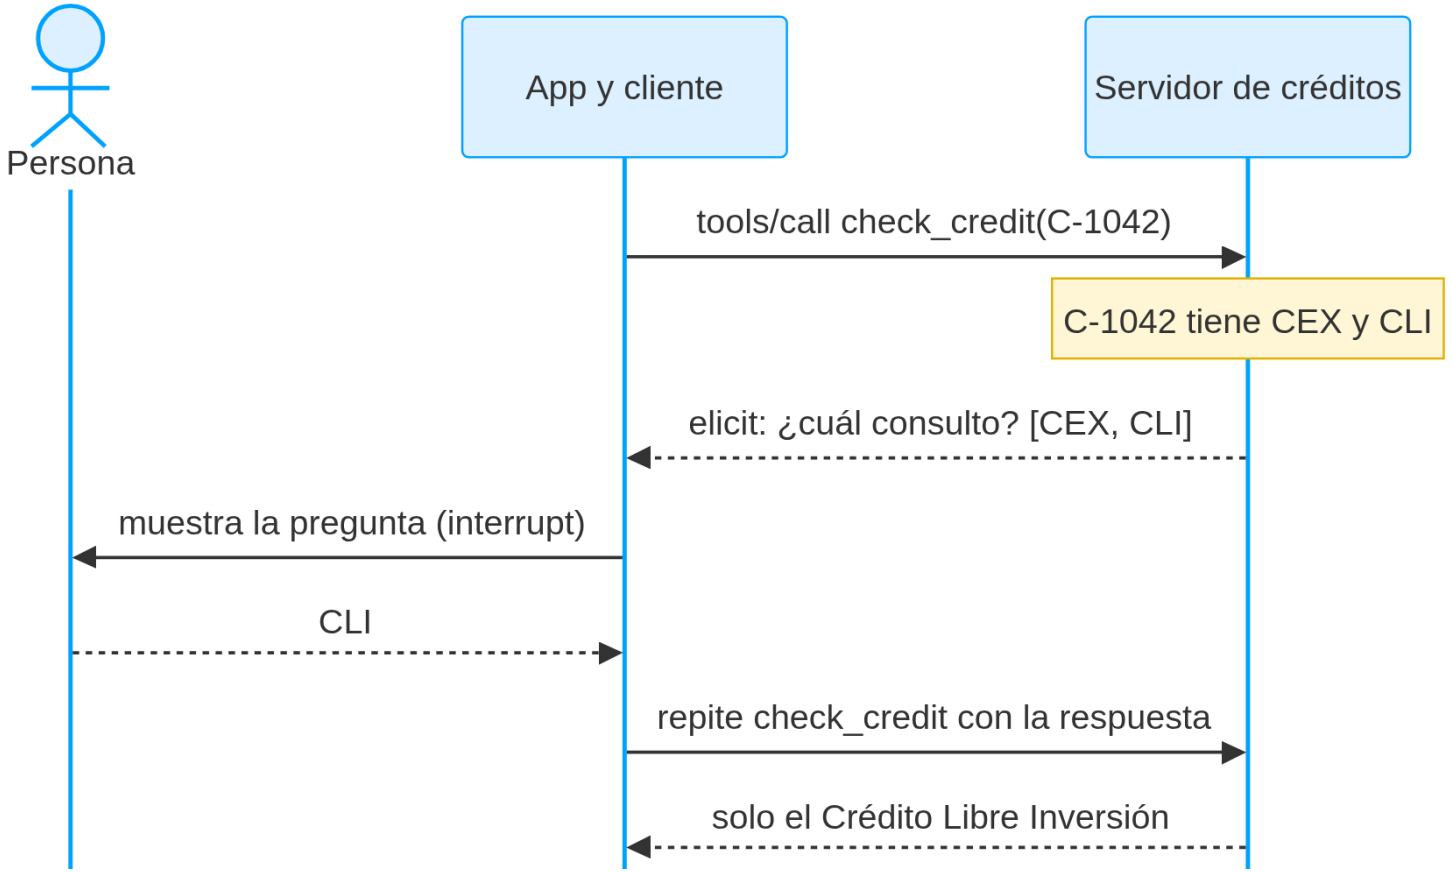
L12 · sección 7

Una pregunta ambigua

1. «Soy el cliente C-1042. ¿Cuánto tengo vencido?»: tiene un CEX y un CLI.
2. El servidor pide a la persona que elija el producto.
3. La respuesta vuelve al servidor y la consulta continúa.

Elicitation paso a paso

Diagrama de secuencia



La persona elige. En el protocolo 2026-07-28 el servidor devuelve la pregunta como resultado intermedio y el cliente repite la operación.

Seguridad

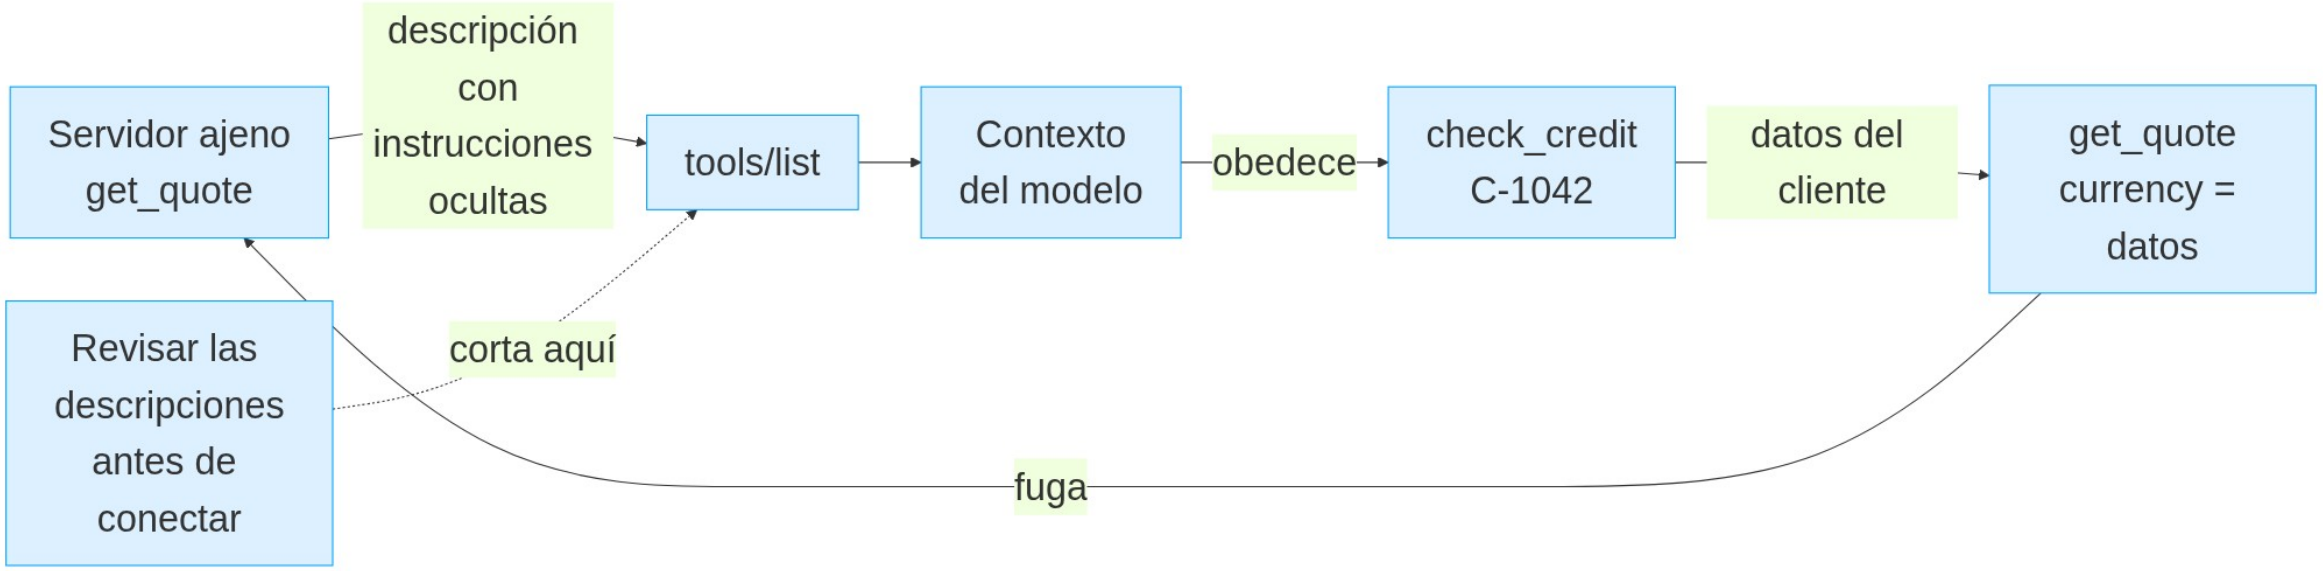
L12 · sección 9

Cada servidor añade riesgo

1. Conceder solo el acceso necesario a datos y operaciones.
2. **Tool poisoning**: la descripción de una tool también es una instrucción para el modelo.
3. Revisar el origen, los permisos y las descripciones antes de conectar un servidor ajeno.
4. Separar claves y registros del canal del protocolo: un servidor stdio no escribe en stdout.

Tool poisoning

L12 · sección 9



Cómo se filtra un dato. La descripción de `get_quote` pide llamar a `check_credit` y enviar el resultado. Revisarla antes de conectar corta la fuga.

Pontificia Universidad JAVERIANA Colombia

Consumir los servidores

L13-MCPAgent

Un agente con dos servidores

L13 · secciones 1 y 2

MCPAdapter

El agente de la semana 3, con tools que viven fuera.

Cómo funciona

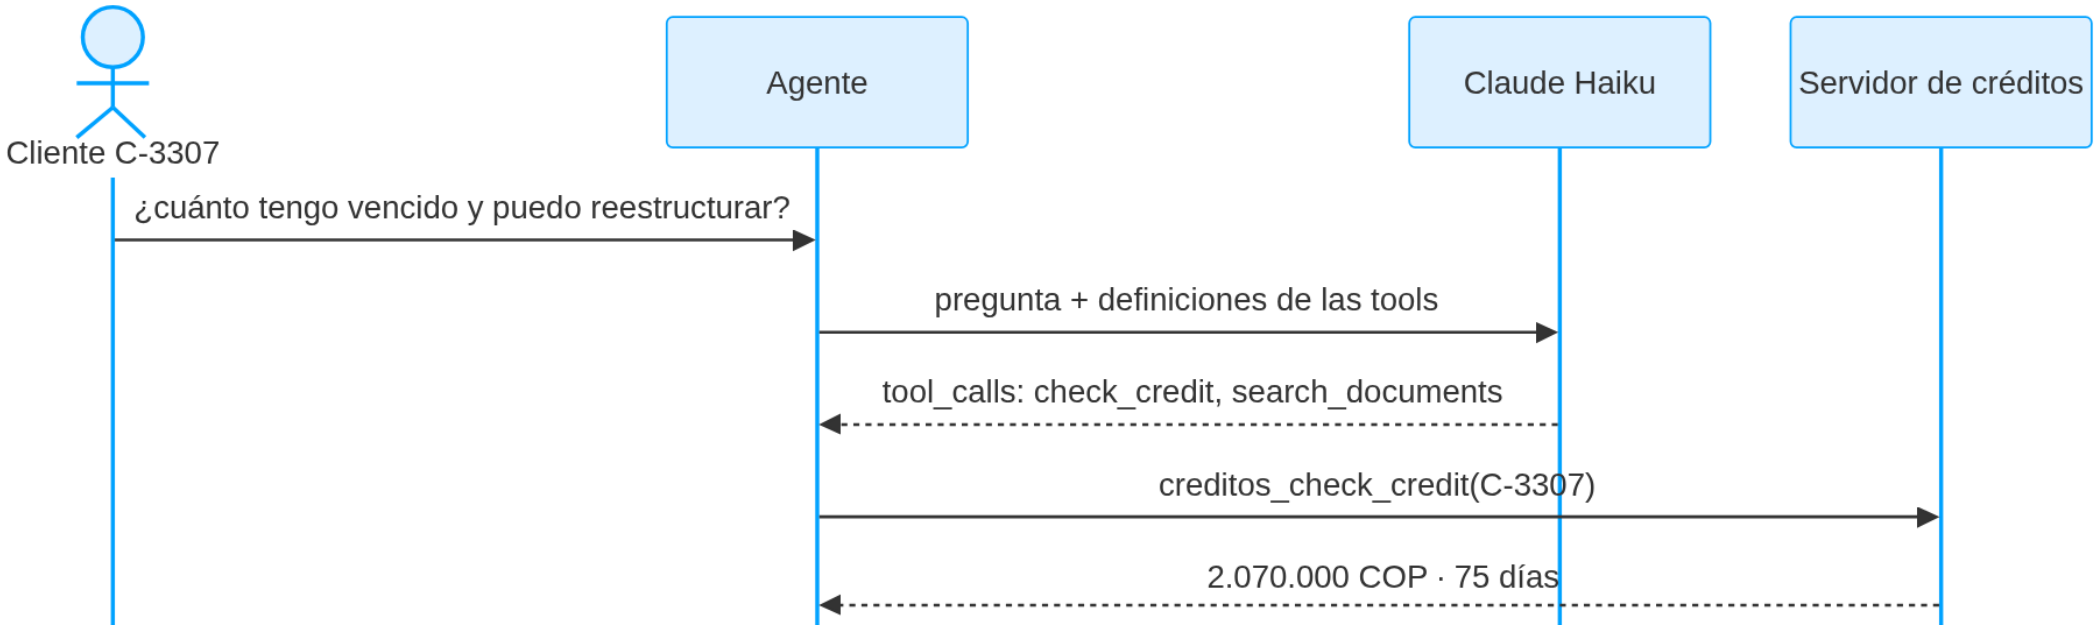
1. Se declaran dos servidores MCP: créditos y documentos.

2. `MCPAdapter` los arranca y convierte sus herramientas en herramientas de LangChain.

3. El mismo `create_agent` de la semana 3 las usa como si fueran locales.

Una pregunta de principio a fin

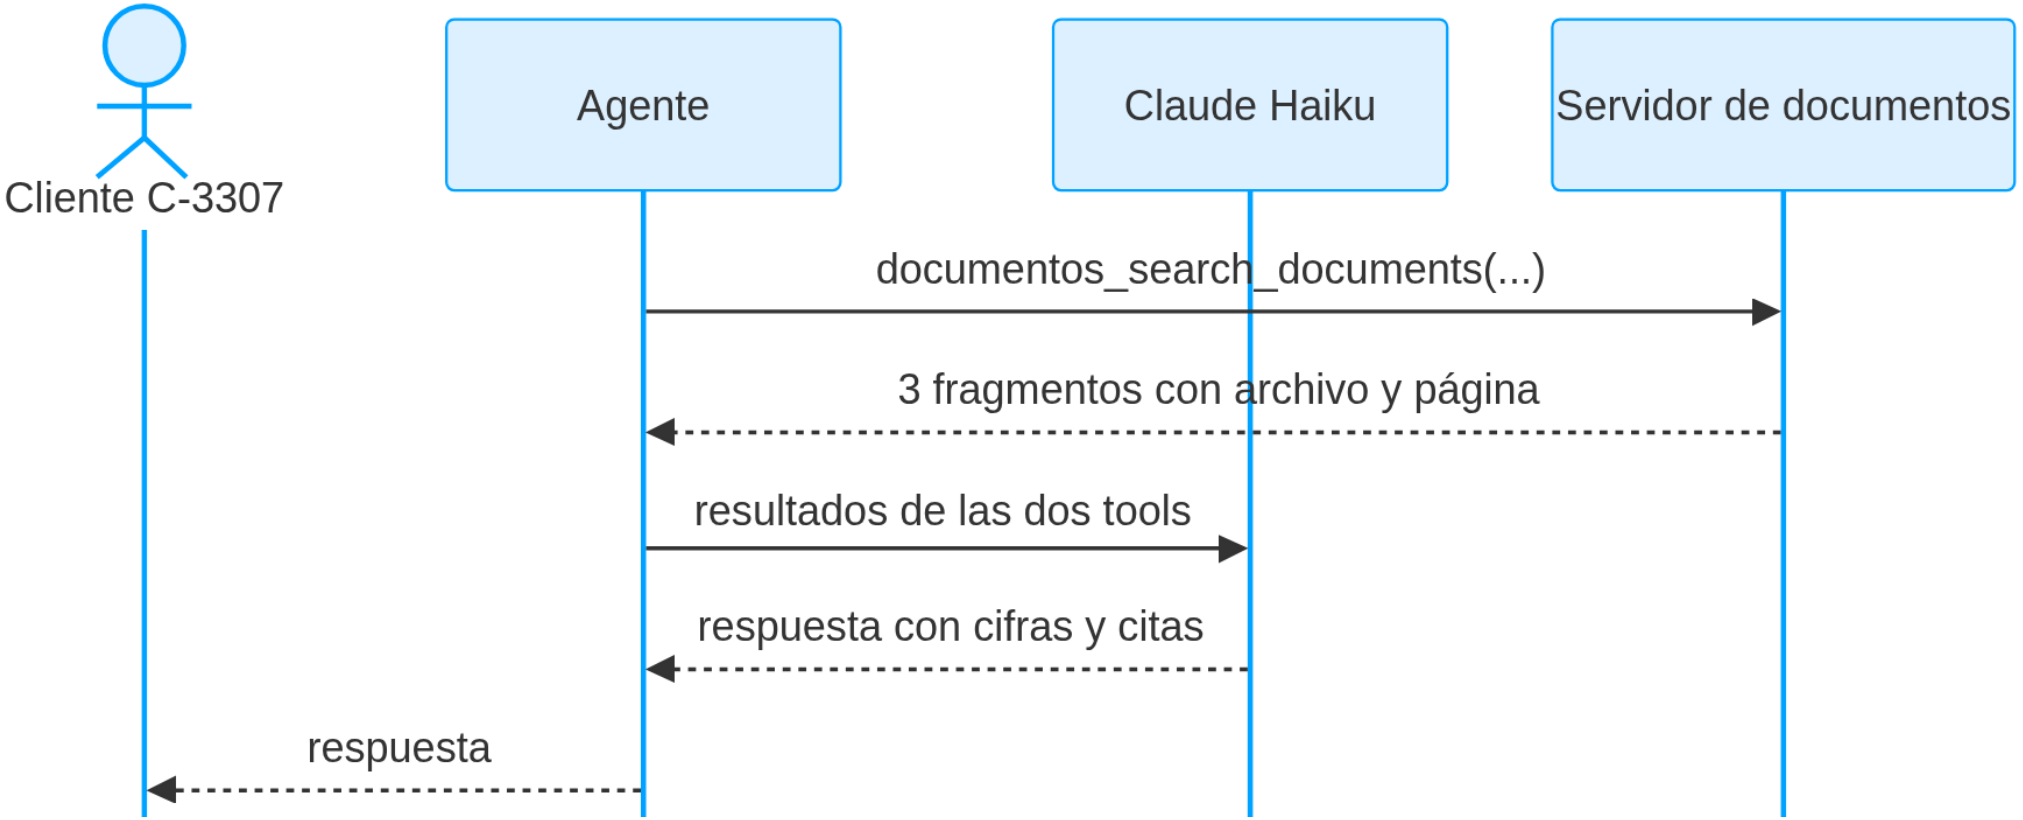
L13 · secciones 2 y 3 · cliente C-3307 · 1 de 2



El modelo pide dos tools. `MCPAdapter` antepone el nombre del servidor: `creditos_` y `documentos_`.

Una pregunta de principio a fin

L13 · secciones 2 y 3 · cliente C-3307 · 2 de 2



Dos servidores, una respuesta. Con los resultados de ambos servidores, el modelo redacta la respuesta con cifras y citas.

Qué servidor respondió

L13 · sección 3 · cliente C-3307

Llamada	Evidencia
`creditos → check_credit`	Vencido 2.070.000 COP · 75 días de mora
`documentos → search_documents`	Reestructuración con hasta 90 días de mora [acme_collections_policy.pdf, p. 2]

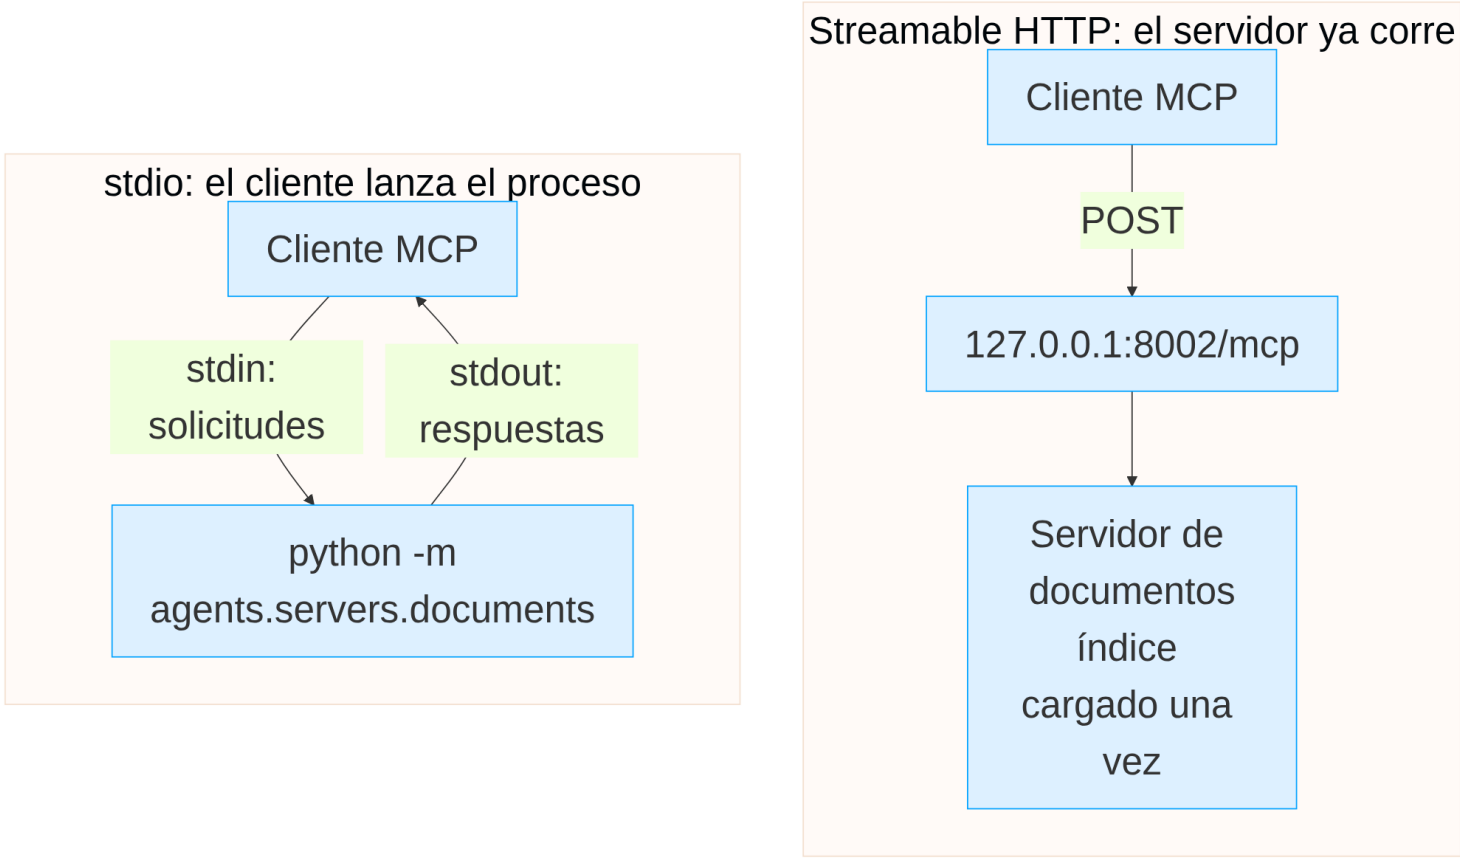
stdio y Streamable HTTP

L13 · secciones 5 y 6

Aspecto	stdio	HTTP
Conexión	Entrada y salida de un proceso	Una URL del servidor
Arranque	Lo gestiona el cliente	Lo iniciamos nosotros
Contrato	`search_documents(query)`	`search_documents(query)`
Claude Code	`.mcp.json` registra los dos servidores	`/mcp` revisa las conexiones

Dos transportes, el mismo contrato

L13 · sección 5



stdio y HTTP. Con stdio el cliente lanza el proceso. Con HTTP el servidor ya está encendido y atiende por una URL.

Muchos servidores, muchas herramientas

L13 · secciones 7 y 8

Descubrimiento

1. El MCP Registry ayuda a encontrar servidores publicados, no garantiza que sean seguros.
2. MCP Inspector permite probar un servidor sin escribir código.
3. Con muchas tools, el descubrimiento progresivo evita llenar el contexto.

Pontificia Universidad JAVERIANA Colombia

Laboratorio

L12-MCPServer · L13-MCPAgent

¿Qué haremos?

Laboratorio

Nuestro recorrido

1. L12: construir el servidor de créditos y probarlo con el cliente, sin modelo.
2. L12: resources, elicitation y el servidor de documentos.
3. L13: un agente con los dos servidores (unas 7 llamadas).
4. L13: elicitation desde el agente, HTTP y Claude Code.

Las ideas que nos llevamos

Cierre

Criterios de construcción

1. MCP separa quién implementa una herramienta de quién la usa.
2. Tool, resource y prompt se diferencian por quién decide usarlos.
3. El transporte cambia; el contrato se mantiene.
4. Los controles de seguridad están en el código del servidor.

Para seguir leyendo

Lecturas de la semana

Fuente	Qué revisar
modelcontextprotocol.io	Arquitectura, primitivas y transportes
SDK de Python de MCP	`MCPServer`, `Client` y elicitation
Documentación de LangChain	`langchain.mcp` y `MCPAdapter`

Pontificia Universidad JAVERIANA Colombia

Próxima semana

LangGraph: estado, nodos, aristas y los primeros patrones de flujo.
Notebooks:
L14 a L19

Sergio Alberto Mora Pardo - H1 2027
GitHub · LinkedIn · Repositorio del curso